Rapport Synthétique : Préparation et Transformation des Données (Projet Superstore)

1. Objectif du Projet Transformer et nettoyer le jeu de données brut "Superstore" pour fournir à la Direction des indicateurs de performance (KPIs) fiables, prêts à être exploités dans un tableau de bord.

2. Nettoyage des Données (Data Cleaning) Afin de garantir l'exactitude des analyses, trois actions majeures ont été effectuées :

- **Valeurs manquantes :** Suppression des lignes sans Postal Code **(dropna)** pour garantir une analyse géographique sans erreurs.
- **Doublons :** Élimination des transactions en double **(drop_duplicates)** pour ne pas gonfler artificiellement le chiffre d'affaires.
- **Formatage :** Conversion des colonnes **Order** Date et Ship Date en format **datetime** pour faciliter les calculs temporels.

3. Création de Nouvelles Variables (Feature Engineering) Pour répondre aux besoins spécifiques des différents départements, nous avons enrichi le jeu de données :

- **Analyse Temporelle :** Extraction de l'année, du mois et du trimestre (quarter) pour étudier la saisonnalité des ventes.
- **Logistique :** Calcul du délai de livraison moyen en jours (delivery_days).
- **Finance :** Création des métriques cost (estimé à 60% des ventes), profit (Ventes - Coûts) et ratio_profit pour évaluer la rentabilité réelle.
- **Commercial :** Segmentation des clients selon la valeur de leurs achats (*High, Medium, Low Value*) pour optimiser le ciblage marketing.

4. Traitement des Valeurs Aberrantes (Outliers)

- **Choix de la méthode :** Nous avons utilisé la méthode de **l'Écart Interquartile (IQR)** sur la colonne Sales pour identifier les anomalies.
- **Justification :** Contrairement à la moyenne ou au Z-Score, l'IQR est une méthode statistique robuste qui n'est pas faussée par les valeurs extrêmes. Elle est idéale pour des données de ventes souvent asymétriques, permettant d'isoler les commandes exceptionnelles (plafond = Q3 + 1.5 * IQR) de manière logique.

5. Agrégations et Résultat Final

- Pour faciliter la lecture par la direction, les données ont été résumées **(groupby)** afin de dégager le Top 10 des produits et le Chiffre d'Affaires par Région.
- **Conclusion :** Le jeu de données final, propre et enrichi, a été exporté sous le nom store_new.csv, prêt pour l'étape de Data Visualisation.